Relatório do projeto da disciplina de Introdução à Teoria da Informação Implementação do algoritmo de compressão e descompressão Lempel-Ziv-Welch (LZW) utilizando a linguagem de programação Python

Jackson Leandro do Nascimento
Universidade Federal da Paraíba
Depto. de Sistemas para Computação
Engenharia da Computação
João Pessoa, Paraíba
Email: jacksonleandro077.hotmail.com@gmail.com

Luiz Eduardo Rodrigues Correa
Universidade Federal da Paraíba
Depto. de Sistemas para Computação
Engenharia da Computação
João Pessoa, Paraíba
Email: lerc.luizrodrigues@gmail.com

Gabriel Assis Guedes Rosas
Universidade Federal da Paraíba
Depto. de Sistemas para Computação
Engenharia da Computação
João Pessoa, Paraíba
Email: weslleydeziderio@eng.ci.ufpb.br

***Abstract*—This report will present and evaluate the results obtained in the development of the project, which is the implementation of the Lempel-Ziv-Welch (LWZ) algorithm, used to compress and decompress data. This algorithm was presented in this discipline (Introduction to Information Theory). For its implementation, the Python language was used.**

08 de maio, 2023

***Resumo*—Neste relatório serão apresentados e avaliados os resultados obtidos no desenvolvimento do projeto, que é a implementação do algoritmo de Lempel-Ziv-Welch (LWZ), usado para fazer compressão e descompressão de dados. Esse algoritmo foi apresentado nesta disciplina (Introdução à Teoria da Informação). Para sua implementação foi usada a linguagem Python.**

08 de maio, 2023

1. Introdução

Para a implementação do algoritmo optou-se por usar a linguagem Python, pois ela é bastante versátil, poderosa e os membros do grupo já possuíam certa familiaridade com ela. As funções para compressão e descompressão foram implementadas em um único arquivo de maneira simples e concisa, com o auxílio de bibliotecas da própria linguagem.

2. Funções de compressão e descompressão

Para o caso desse projeto, o professor forneceu dois arquivos para serem utilizados nos testes, um arquivo de texto (.txt) e um arquivo de vídeo (.mp4) e ambos deveriam ser tratados pelo algoritmo para compressão e posteriormente descompressão, para que possamos validar a implementação.

2.1. Compressão

Em uma breve explicação temos que, o algoritmo de compressão recebe dois parâmetros, o dados do arquivo que será comprimido e o tamanho máximo do dicionário que será usado durante o processo de compressão. A função inicializa com os primeiros 256 caracteres padrão da tabela ASCII como chaves e seus respectivos valores em bytes, em seguida itera pelos dados de entrada, construindo um *buffer* até encontrar uma sequência de bytes que não esteja no dicionário. Quando isso ocorre, a função gera o código correspondente ao *buffer*, adiciona a nova sequência ao dicionário e define o *buffer* para o símbolo de byte atual. A função também usa o método "struct.pack()"para empacotar os códigos de saída no formato *little-endian* de 2 bytes e os anexa a um *bytearray* chamado "resultado", que conterá os dados compactados. Por fim, ele gera os dados compactados e o tamanho do dicionário, que será útil para a descompressão.

2.2. Descompressão

Já para a função de descompressão temos o seguinte funcionamento, inicia-se criando um dicionário com as chaves em bytes e os valores inteiros que vão de 0 a 255 (totalizando os 256 valores da tabela ASCII). Em seguida ele inicializa variáveis para armazenar valores de modo temporário. No *loop* principal tem-se o processo de desempacotamento do próximo par de bytes do arquivo de entrada e converte para um número inteiro usando o método "struct.unpack()", é então verificado se o código descompactado está presente no dicionário, caso esteja o valor é adicionado a uma variável. Caso contrário cria-se um novo valor adicionando o primeiro caractere do *buffer* no final e o adiciona ao dicionário. Então esse valor é adicionado à variável "resultado"que armazena a descompactação no final do arquivo, logo em seguida verifica-se se o *buffer* já possui um valor, caso tenha ele adiciona a sequência atual do dicionário, desde que o mesmo não esteja cheio. Caso contrário apenas adiciona-se o valor atual ao buffer. E por fim o código retorna a variável "resultado"que contém a descompressão completa do arquivo e seu tamanho final do dicionário.

3. Valores de 'K' utilizados

Todos os valores de K (neste caso do 9 ao 16, pois foi implementado o LZW) funcionaram bem, tanto para o arquivo de texto quanto para o de vídeo.

4. Obtenção do valor exato de 'K' bits

Para essa finalidade conseguimos salvar o valor de bits ao salvá-los em índices de 2 bytes.

5. Razão de diferentes 'RCs' x K

Para esse projeto tivemos que utilizar duas expressões diferentes para a obtenção da razão de compressão (RC), e para

fins de auxiliar na elaboração do relatório elas serão nomeadas como RC1 e RC2, da seguinte forma:

$$RC1 = \frac{tamArqOriginal}{tamArqComprimido}$$

$$RC2 = \frac{tamArqOriginal}{\frac{totalIndices * K}{8}}$$

5.1. Curva dos 'RCs' x K para o arquivo de texto

Para o RC1 obtivemos o seguinte gráfico:

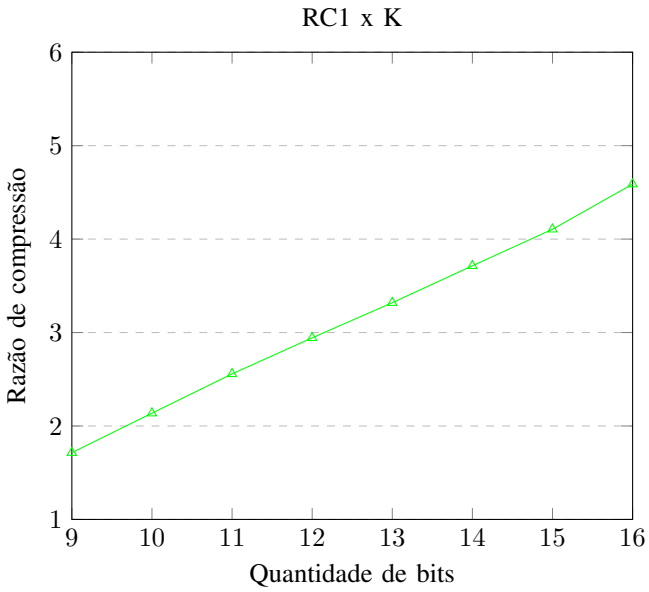

Para o RC2 obtivemos o seguinte gráfico:

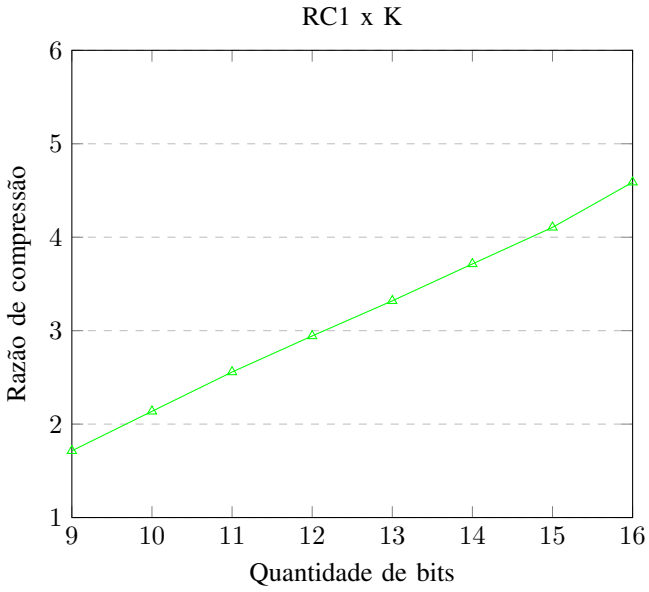

5.2. Curva dos 'RCs' x K para o arquivo de vídeo

Para o caso do RC1 obtivemos o gráfico a seguir:

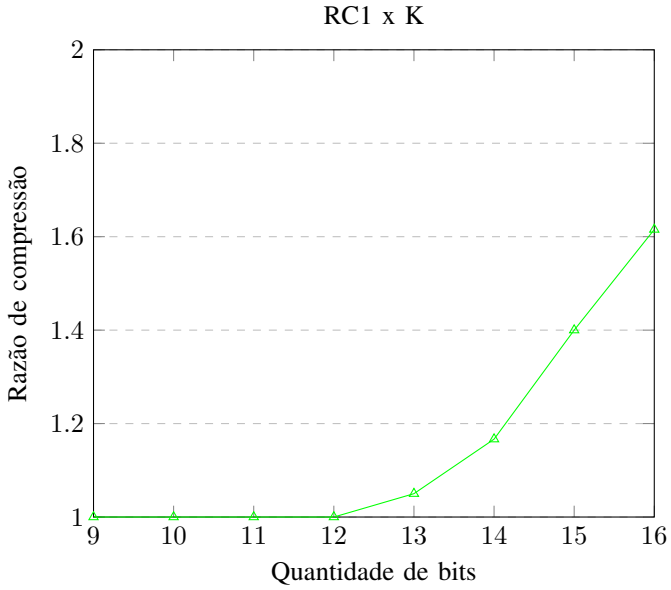

Para o caso do RC2 obtivemos o gráfico a seguir:

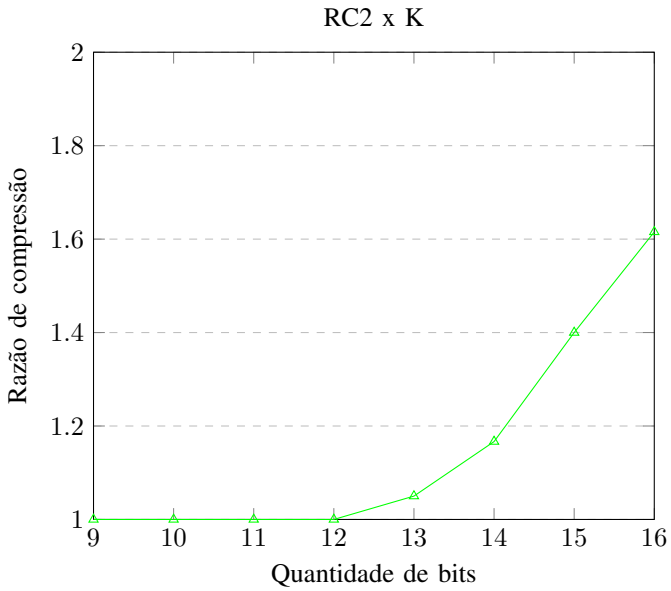

6. Curvas de Tempo x K

Para esta análise utilizamos a soma de todo o tempo de processamento do algoritmo.

6.1. Curva de Tempo x K para o arquivo de texto

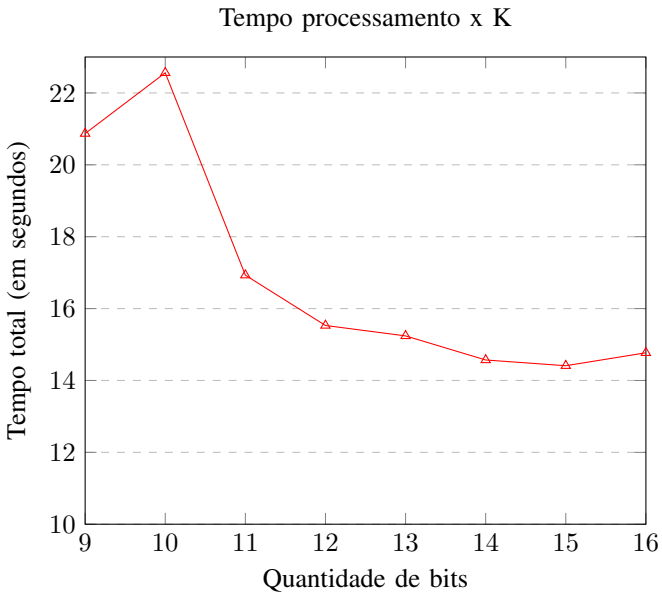

6.2. Curva de Tempo x K para o arquivo de vídeo

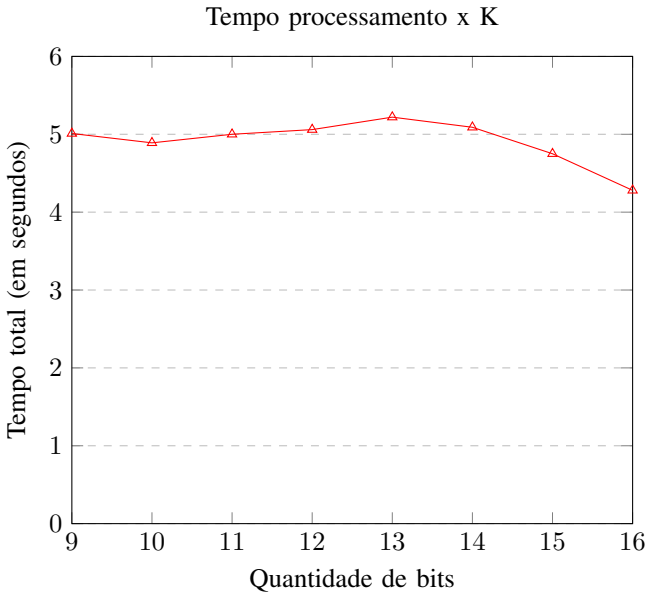

7. Estaticidade do dicionário

Depois que o dicionário atinge o seu tamanho máximo, ele permanece estático. Salientando que seu valor máximo depende do 2^k, temos como valor máximo $2^{16} = 65536$